Business Intelligence

Proyecto final · Entrega 2

Data warehouse, ETL y tablero

Sistema de Inteligencia de Negocios para el Monitoreo de Matrícula en la Educación Superior

Integrante	Código
Daniel Felipe Grisales Corredor	506232081
Giancarlo Guevara Orjuela	507211010
Johan Arturo González Feo	507242006

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	06/11/2026
Repositorio	https://github.com/papagrosly-boop/bi-proyecto-equipo506232081y507211010y507242006.git
Motor de base de datos	MySQL 8.0.46
Herramienta del tablero	Power BI Desktop

Resumen de la entrega

Se construyó el data warehouse del caso del Ministerio de Educación Nacional (matrícula de educación superior 2015-2021) en MySQL 8.0.46, con un esquema en estrella de 6 tablas: 5 dimensiones (`dim_tiempo`, `dim_institucion`, `dim_programa`, `dim_geografia`, `dim_genero`) y la tabla de hechos `fact_matricula`, que quedó con **230.078 registros**. La carga se hace con cinco transformaciones de Pentaho Data Integration (PDI) y un trabajo (`j_carga_dw.kjb`) que ejecuta las dimensiones primero y los hechos al final, leyendo las tres fuentes originales (dos CSV y un XML) sin modificarlas. La conciliación cuadra: de las 390.903 filas de matrícula leídas, 230.078 se cargaron y 160.825 se descartaron por duplicados. El tablero en Power BI está conectado a la base `matricula` y responde las preguntas P0, P1 y P2.

Respuesta a la pregunta principal (P0). La matrícula se concentra en Bogotá, D.C., que acumula cerca de 4,5 millones de matriculados del semestre 1 entre 2015 y 2021, seguida de Antioquia (cerca de 1,8 millones) y Valle del Cauca (cerca de 1,0 millón). A nivel nacional, la matrícula del semestre 1 pasó de 1.867.703 estudiantes en 2015 a 1.995.185 en 2021 (+6,8 %), con una caída en 2020 (1.930.934) y una recuperación de 3,33 % en 2021.

1. Modelo físico

1.1 Motor y base de datos

- **Motor y versión:** MySQL 8.0.46 Community Server, instalado en un equipo local de uno de los integrantes. La Entrega 1 propuso MySQL en la nube; para esta entrega el enunciado recomienda una instancia propia, y el servidor local se usa como entorno de construcción y ejecución.
- **Base de datos:** `matricula`, con conjunto de caracteres `utf8mb4` para conservar tildes y la ñ.
- **Esquemas:** un solo esquema (`matricula`) con las tablas del data warehouse. No se creó capa de staging: el enunciado la recomienda pero no la exige, y las transformaciones de PDI leen directamente de los archivos originales.
- **Usuario de carga:** `etl`, con privilegios únicamente sobre `matricula.*`. La contraseña no se guarda en el repositorio: PDI la toma de variables definidas en el archivo `kettle.properties` de cada equipo.
- **Scripts:** el script `dw/ddl/00_crear_todo.sql` crea la base, las seis tablas, las llaves y la dimensión de tiempo completa; además hay un script por tabla en `dw/ddl/`.

1.2 Tablas creadas

Cada dimensión tiene una llave subrogada (`sk_...`, generada con `AUTO_INCREMENT`) y conserva la llave de la fuente como atributo. Cada dimensión incluye una fila «Desconocido» con llave −1, que recibe los hechos cuya llave no se encuentra en la dimensión. Los registros incluyen esa fila.

Tabla	Tipo	Llave primaria	Llaves foráneas	Registros	Script DDL
dim_tiempo	Dimensión	sk_tiempo	—	14	dw/ddl/01_dim_tiempo.sql
dim_institucion	Dimensión	sk_institucion	—	362	dw/ddl/02_dim_institucion.sql
dim_programa	Dimensión	sk_programa	—	15.527	dw/ddl/03_dim_programa.sql
dim_geografia	Dimensión	sk_geografia	—	1.123	dw/ddl/04_dim_geografia.sql
dim_genero	Dimensión	sk_genero	—	3	dw/ddl/05_dim_genero.sql

Tabla	Tipo	Llave primaria	Llaves foráneas	Registros	Script DDL
fact_matricula	Hechos	(sk_tiempo, sk_institucion, sk_programa, sk_geografia, sk_genero)	sk_tiempo, sk_institucion, sk_programa, sk_geografia, sk_genero	230.078	dw/ddl/06_fact_matricula.sql

Atributos principales

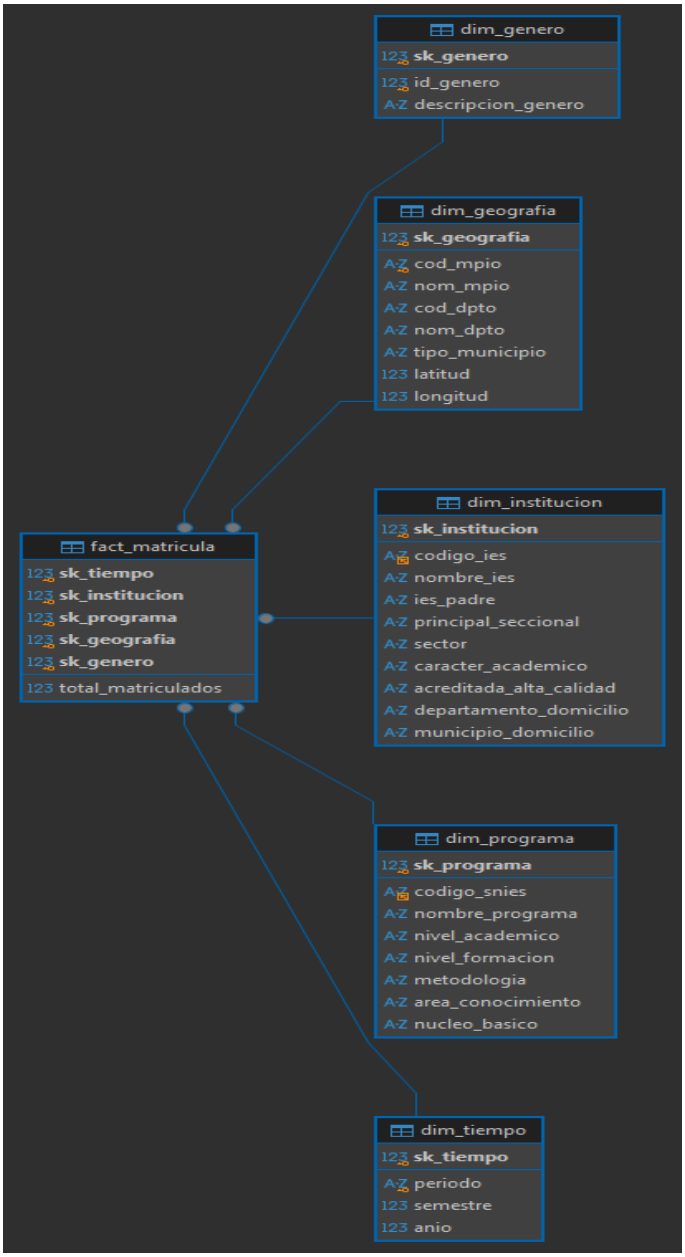
- `dim_tiempo`: periodo, semestre y año.
- `dim_institucion`: código de la IES (llave de la fuente), nombre, `ies_padre`, principal/seccional, sector, carácter académico, acreditada de alta calidad (SI/NO), departamento y municipio de domicilio.
- `dim_programa`: código SNIES (llave de la fuente), nombre del programa, nivel académico, nivel de formación, metodología, área de conocimiento y núcleo básico del conocimiento.
- `dim_geografia`: código y nombre del municipio, código y nombre del departamento, tipo de municipio, latitud y longitud (`DECIMAL(9,6)`).
- `dim_genero`: código de género y descripción.
- `fact_matricula`: las cinco llaves subrogadas y la métrica `total_matriculados` (entero). La llave primaria compuesta obliga a respetar la granularidad definida en la Entrega 1: una fila por programa, institución, municipio, género y semestre de un año.

Decisiones y supuestos del modelo

- `ies_padre` quedó vacío: F1 no trae ese dato y no se cargó desde F2 para no complicar la carga.
- `nivel_academico`, `nivel_formacion`, `metodologia` y `area_conocimiento` guardan el código de F2, porque la fuente no trae el texto asociado.
- La descripción de género asigna 1 = Masculino y 2 = Femenino. Es un supuesto: el archivo solo trae el código y no su significado, y se infirió a partir de la participación de cada código en la matrícula. Debe confirmarse con la ficha del conjunto de datos en datos.gov.co.

1.3 Diagrama del modelo físico

El esquema implementado es una **estrella**: la tabla de hechos `fact_matricula` se conecta directamente con las cinco dimensiones, sin dimensiones normalizadas adicionales. El diagrama se generó desde la base ya creada con la vista ER de DBeaver y está en `docs/diagramas/`.



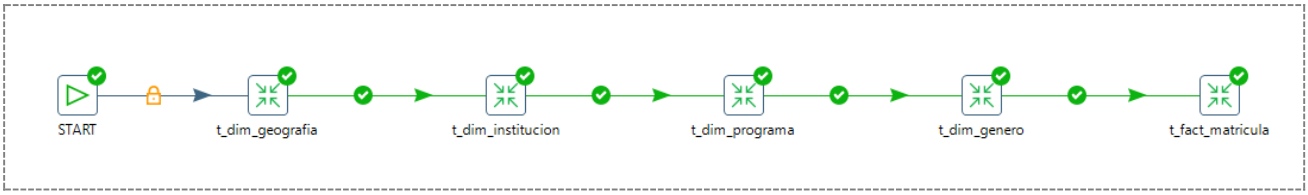
1.4 Dimensión de tiempo

- **Rango cubierto:** del semestre 1 de 2015 al semestre 2 de 2021, es decir, 14 registros sin huecos. Cubre todo el periodo de los hechos de F2 (años 2015 a 2021, semestres 1 y 2).
- **Cómo se pobló:** con un script SQL (`dw/ddl/01_dim_tiempo.sql`, que también está incluido en `00_crear_todo.sql`), sin transformación de PDI.
- **Atributos:** llave subrogada (`sk_tiempo`), periodo, semestre y año. La jerarquía es semestre → año.
- **Búsqueda desde los hechos:** la transformación de hechos hace un Database lookup (`lookup_tiempo`) por año y semestre; los 14 periodos fueron encontrados para todas las filas.

2. Procesos ETL

2.1 Trabajo de carga

El trabajo `j_carga_dw.kjb` (en `etl/trabajos/`) ejecuta las cinco transformaciones en este orden: `t_dim_geografia`, `t_dim_institucion`, `t_dim_programa`, `t_dim_genero` y, al final, `t_fact_matricula`. Las dimensiones van primero porque la tabla de hechos busca sus llaves subrogadas en ellas. Las rutas de las fuentes y los datos de conexión se leen de variables (`FUENTES_DIR`, `DB_HOST`, `DB_NAME`, `DB_USER`, `DB_PASS`), de modo que los archivos del repositorio no contienen contraseñas.



2.2 Transformaciones

Las dimensiones se cargan con el paso Insert/Update, que permite repetir la carga sin duplicar filas. Los registros «escritos» no incluyen la fila «Desconocido», que viene del script DDL.

Archivo .ktr	Fuente(s) y formato	Destino	Pasos principales	Leídos	Escritos	Rechazos
t_dim_geografia.ktr	F3 DIVIPOLA (XML)	dim_geografia	lee_divipola_xml (Get data from XML) → coma_a_punto (Replace in string) → carga_dim_geografia (Insert/Update)	1.122	1.122	0
t_dim_institucion.ktr	F1 Instituciones de Educación Superior (CSV)	dim_institucion	lee_instituciones_csv (CSV file input) → limpia_codigo_ies (Replace in string) → limpia_texto_institucion (Replace in string) → carga_dim_institucion (Insert/Update)	361	361	0
t_dim_programa.ktr	F2 Matrícula estadística (CSV)	dim_programa	lee_matricula_csv (CSV file input) → quita_duplicados_programa (Unique rows) → limpia_texto_programa (Replace in string) → carga_dim_programa (Insert/Update)	390.903	15.526	0

Archivo .ktr	Fuente(s) y formato	Destino	Pasos principales	Leídos	Escritos	Rechazos
t_dim_genero.ktr	F2 Matrícula estadística (CSV)	dim_genero	lee_matricula_csv (CSV file input) → quita_duplicados_genero (Unique rows) → asigna_descripcion (Value Mapper) → carga_dim_genero (Insert/Update)	390.903	2	0
t_fact_matricula.ktr	F2 Matrícula estadística (CSV)	fact_matricula	lee_matricula_csv → quita_duplicados (Unique rows) → rellena_cero_mpio (Replace in string) → lookup_tiempo, lookup_institucion, lookup_programa, lookup_geografia, lookup_genero (Database lookup) → ordena_llaves (Sort rows) → agrupa_grano (Group by) → carga_fact_matricula (Table output)	390.903	230.078	0

Notas sobre la transformación de hechos:

- Las cinco búsquedas de llaves usan la llave de la fuente (código de institución, código SNIES, código de municipio, género, año y semestre). Si no hay coincidencia, el hecho recibe la llave −1 («Desconocido»). Así quedaron 78 hechos con institución desconocida, y ninguno con programa, geografía, género o tiempo desconocidos.
- `agrupa_grano` agrupa por las cinco llaves y conserva el valor máximo de `total_matriculados`. Esto hace que cada fila de hechos respete la granularidad (una por combinación de programa, institución, municipio, género y semestre), porque 54.216 combinaciones venían repetidas con el departamento o el municipio escrito de otra forma. En casi todas el total es el mismo; en las pocas con totales distintos se conserva el mayor.
- `carga_fact_matricula` vacía la tabla antes de cargar, por lo que el trabajo puede ejecutarse varias veces con el mismo resultado.

2.3 Reglas de limpieza aplicadas

Cada fila corresponde a un problema de calidad de la tabla 2.2 de la Entrega 1. La última fila es un problema adicional que apareció al ejecutar la carga.

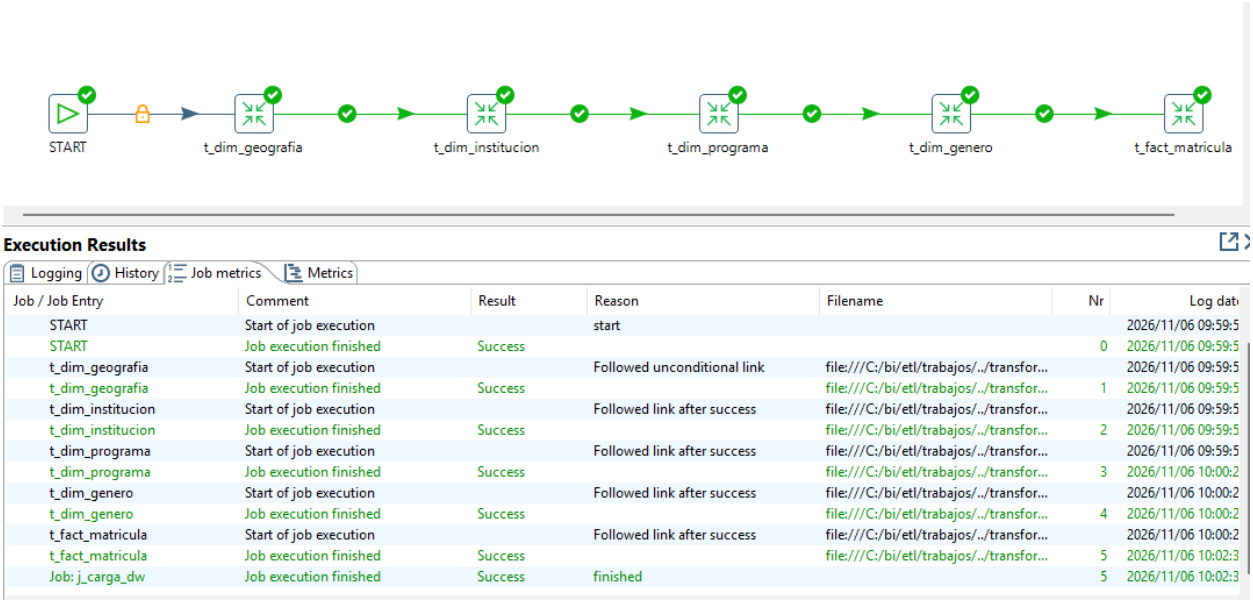
Problema (Entrega 1)	Fuente y campo	Regla aplicada	Paso de PDI (nombre)	Registros afectados
Caracteres corruptos	F1 Dirección Domicilio	El campo no se incluye en el modelo, por lo que no pasa al data warehouse	No aplica: campo no cargado	41 (detectados en F1)

Problema (Entrega 1)	Fuente y campo	Regla aplicada	Paso de PDI (nombre)	Registros afectados
Fechas imposibles	F1 Fecha Norma de Creación	El campo no se incluye en el modelo, por lo que las fechas imposibles no pasan al data warehouse	No aplica: campo no cargado	30 (detectados en F1)
Código como texto con punto, distinto de la matrícula	F1 Código Institución	Quitar el punto de miles para que coincida con el código de F2 (por ejemplo, «1.123» pasa a «1123»)	limpia_codigo_ies (Replace in string)	361 (todos los códigos de F1)
Filas duplicadas	F2 (fila completa)	Descartar las filas idénticas y, después, agrupar por las cinco llaves del grano	quita_duplicados (Unique rows) y agrupa_grano (Group by)	106.609 duplicados exactos y 54.216 por agrupación
Misma entidad escrita de muchas formas	F2 Departamento de oferta del programa	Se descarta el nombre escrito en F2: el nombre del departamento se toma de DIVIPOLA, buscando por el código del municipio	lookup_geografia (Database lookup)	390.903 (todas las filas de F2 usan el nombre de F3)
Código de municipio con y sin cero a la izquierda	F2 Código del Municipio(Programa)	Completar con un cero los códigos de 4 dígitos para que coincidan con los de 5 dígitos de DIVIPOLA («5001» pasa a «05001»)	rellena_cero_mpio (Replace in string)	366.590 (24.313 ya traían el cero)
Coma decimal y texto en coordenadas	F3 longitud y latitud	Cambiar la coma por punto; la columna destino es `DECIMAL(9,6)`	coma_a_punto (Replace in string)	1.122
Nombre de municipio repetido entre departamentos	F3 nom_mpio	El cruce se hace por el código del municipio, nunca por el nombre	lookup_geografia (Database lookup, llave cod_mpio)	1.122 (todo el catálogo se cruza por código)
Categorías que no son municipio	F3 tipo_municipio	Se conservan con su tipo como atributo de la dimensión, para poder excluirlas en el análisis si se desea	carga_dim_geografia (Insert/Update)	19 (18 áreas no municipalizadas y 1 isla)
Caracteres corruptos en nombres	F2 Programa Académico y Núcleo Básico; F1 nombres de institución, departamento y municipio	Eliminar el carácter «¿»	limpia_texto_programa y limpia_texto_institucion (Replace in string)	3.555 (programas en F2)
Total de matriculados con separador de miles (problema nuevo)	F2 Total Matriculados	Leer el campo con símbolo de agrupación «.» y símbolo decimal «,» para convertir «1.004» en 1004	lee_matricula_csv (CSV file input, formato del campo)	--

Nota sobre la regla de duplicados: la Entrega 1 reportó 106.599 filas repetidas; PDI descartó 106.609 duplicados exactos, diez más. La diferencia se atribuye a que PDI compara los valores ya convertidos de tipo y con los espacios sobrantes recortados, por lo que diez filas que antes se veían distintas quedaron iguales.

2.4 Evidencia de ejecución

El trabajo `j_carga_dw.kjb` se ejecutó completo sobre una base vacía: se eliminó la base con `DROP DATABASE matricula;`, se volvió a crear con `00_crear_todo.sql` y se ejecutó el trabajo, que terminó sin errores. La captura muestra el resultado del trabajo; las capturas de las métricas de pasos de cada transformación están en el Anexo B.



Métricas de pasos de la transformación de hechos (ejecución de `t_fact_matricula`):

Paso	Leídos	Escritos	Errores
lee_matricula_csv	—	390.903	0
quita_duplicados	390.903	284.294	0
rellena_cero_mpio	284.294	284.294	0
lookup_tiempo	284.294	284.294	0
lookup_institucion	284.294	284.294	0
lookup_programa	284.294	284.294	0
lookup_geografia	284.294	284.294	0
lookup_genero	284.294	284.294	0
ordena_llaves	284.294	284.294	0
agrupa_grano	284.294	230.078	0
carga_fact_matricula	230.078	230.078	0

3. Conciliación

3.1 Conteo por fuente

Para cada fuente se cumple: leídos = cargados + descartados.

Fuente	Leídos	Cargados	Descartados	Motivo de los descartes
F1 Instituciones (CSV)	361	361	0	Ninguno: todas las instituciones se cargaron en `dim_institucion` (362 filas con la fila «Desconocido»)
F2 Matrícula (CSV)	390.903	230.078	160.825	106.609 filas duplicadas exactas (paso `quita_duplicados`) y 54.216 filas que repetían una misma combinación de programa, institución, municipio, género y semestre (paso `agrupa_grano`)
F3 DIVIPOLA (XML)	1.122	1.122	0	Ninguno: todos los registros se cargaron en `dim_geografia` (1.123 filas con la fila «Desconocido»)

Verificación de F2: 230.078 + 106.609 + 54.216 = 390.903.

Hechos con llave «Desconocido» (llave −1) después de la carga: 78 con institución desconocida, que corresponden a códigos de institución de la matrícula que no están en el catálogo F1 (problema S2 de la Entrega 1); 0 con programa, geografía o género desconocidos.

3.2 Totales de una métrica

Métrica comparada: `total_matriculados`, sumada sobre toda la tabla de hechos.

Métrica	Total en la fuente	Total en el DW	Diferencia y explicación
total_matriculados	24.914.033 (F2 completa, 390.903 filas)	16.774.645	8.139.388. Se explica por los duplicados: las filas exactas descartadas suman 7.166.492 (24.914.033 − 17.747.541) y las filas descartadas al agrupar suman 972.896 (17.747.541 − 16.774.645).
total_matriculados	17.747.541 (F2 sin duplicados exactos, 284.294 filas)	16.774.645	972.896. Son los totales de las 54.216 filas que repetían una combinación ya cargada; en la mayoría de los casos el total coincide con el de la fila conservada, de modo que no se pierde matrícula, solo se evita contarla dos veces.

La matrícula es una métrica semiaditiva: se suma entre institución, programa, geografía y género, pero no entre los dos semestres de un año. Por eso el tablero usa el semestre 1 como referencia. El desglose por año y semestre de la tabla de hechos está en el Anexo A.

4. Tablero

El tablero (`dashboard/tablero_matricula.pbix`) se conecta a la base de datos `matricula` del data warehouse (conector de MySQL en modo importar) y usa las tablas `dim_*` y `fact_matricula`; no usa los archivos de las fuentes. Tiene tres páginas, una por pregunta de negocio.

4.1 Indicadores

Indicador	Fórmula (DAX o SQL)	Qué mide	Referencia	Pregunta

Matrícula del semestre 1 frente al año anterior	`Matricula_S1 = CALCULATE(SUM(fact_matricula[total_matriculados]), dim_tiempo[semestre] = 1)`
	
	`Matricula_S1_AnioAnt = CALCULATE([Matricula_S1], FILTER(ALL(dim_tiempo[anio]), dim_tiempo[anio] = MAX(dim_tiempo[anio]) - 1))`
	
	`Variacion_Anual = DIVIDE([Matricula_S1] - [Matricula_S1_AnioAnt], [Matricula_S1_AnioAnt])`
		Estudiantes matriculados en el semestre 1 del año seleccionado y su variación frente al año anterior	Periodo anterior: 2021 tuvo 1.995.185 frente a 1.930.934 en 2020 (+3,33 %)	P0

% de matrícula en instituciones acreditadas	`Pct_Acreditadas = DIVIDE(CALCULATE([Matricula_S1], dim_institucion[acreditada_alta_calidad] = "SI"), [Matricula_S1])`
	
	`Pct_Acreditadas_Promedio = CALCULATE([Pct_Acreditadas], ALL(dim_tiempo))`
		Proporción de la matrícula del semestre 1 que está en instituciones con acreditación de alta calidad	Promedio de todos los años (`Pct_Acreditadas_Promedio`); valor mostrado: 58,25 %	P1

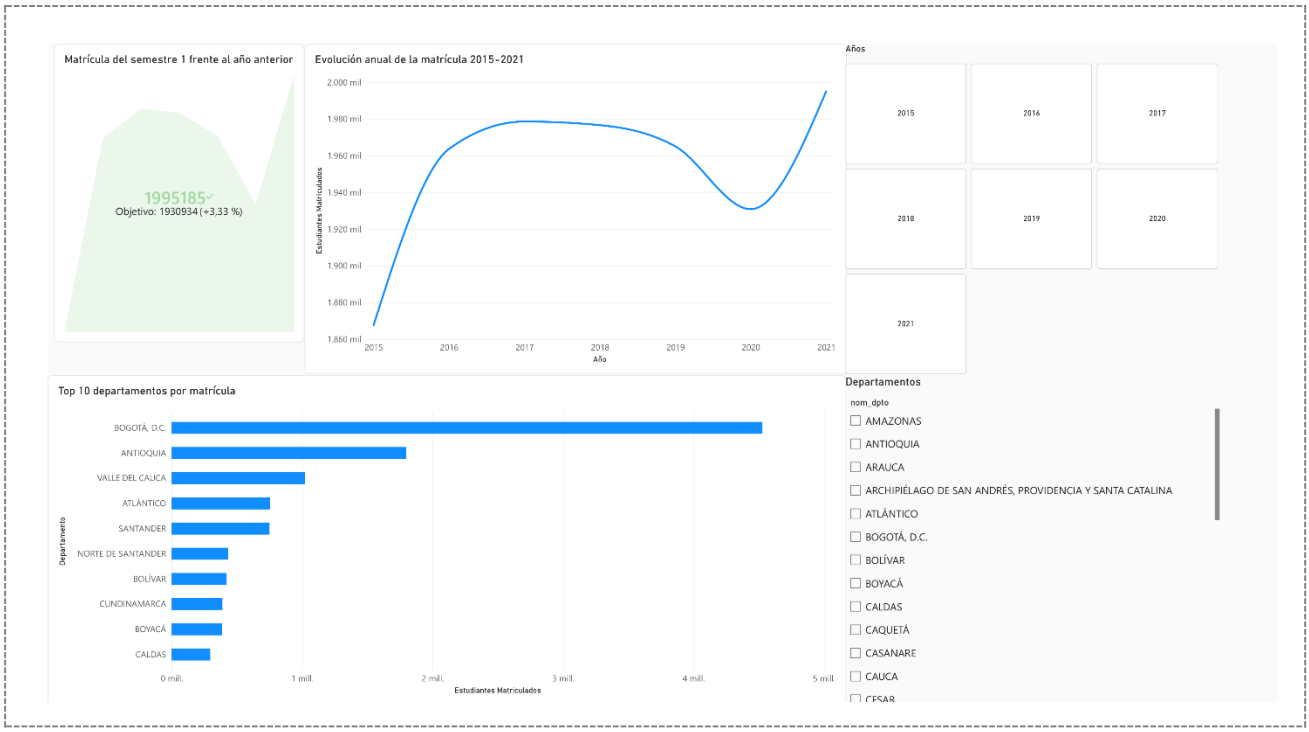
Municipios con oferta	`Municipios_Oferta = CALCULATE(DISTINCTCOUNT(fact_matricula[sk_geografia]), dim_tiempo[semestre] = 1)`
	
	`Municipios_Oferta_AnioAnt = CALCULATE([Municipios_Oferta], FILTER(ALL(dim_tiempo[anio]), dim_tiempo[anio] = MAX(dim_tiempo[anio]) - 1))`
		Número de municipios donde se registra matrícula en el semestre 1	Periodo anterior (`Municipios_Oferta_AnioAnt`); valor mostrado: 832	P0

4.2 Respuesta a las preguntas de negocio

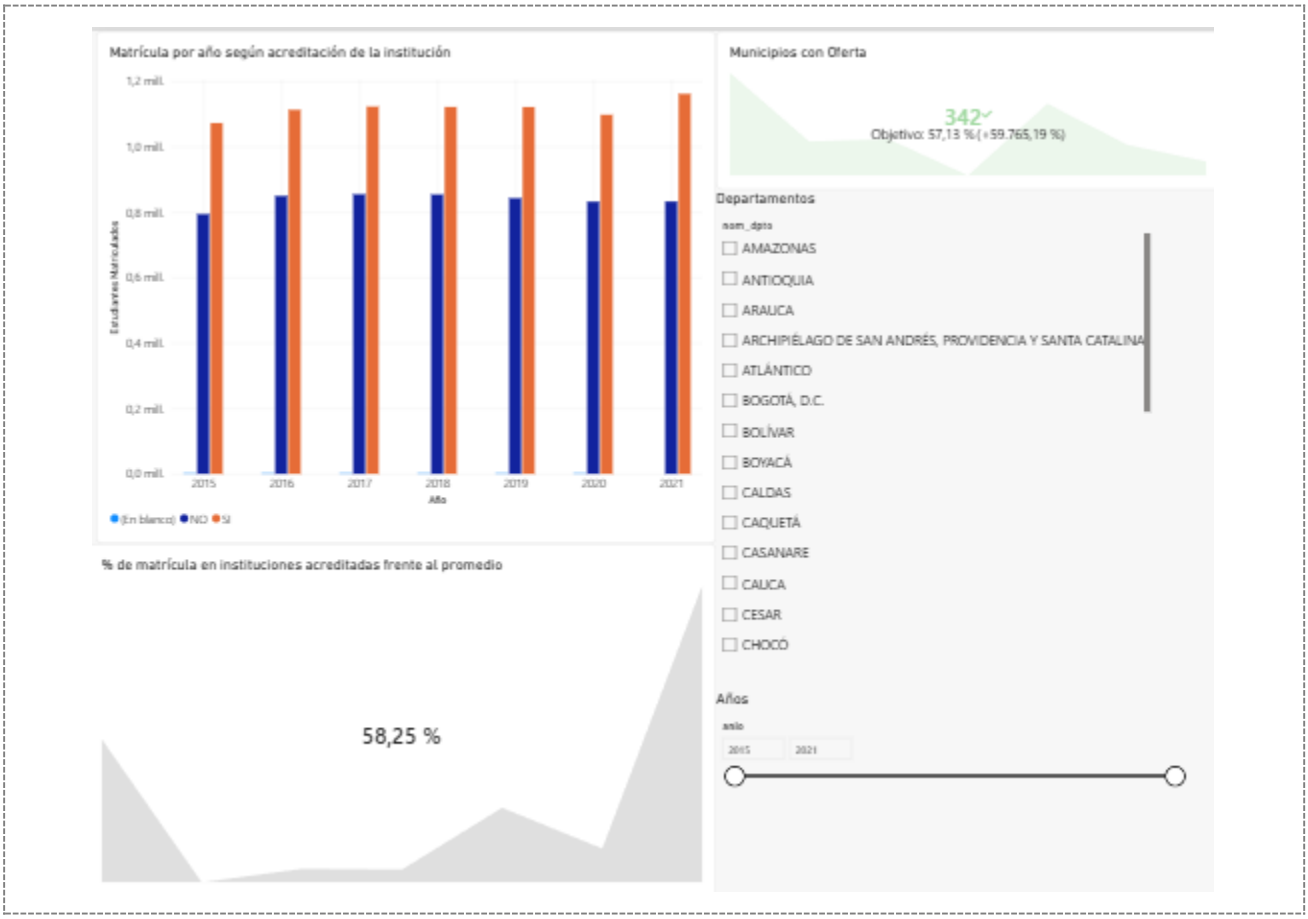
Pregunta	Página y visual	Tipo de gráfico y por qué	Respuesta encontrada (con cifra)
P0. ¿En qué departamentos y áreas del conocimiento se concentra la matrícula y cómo ha cambiado entre 2015 y 2021?	Página 1 «Matrícula»: «Top 10 departamentos por matrícula», «Evolución anual de la matrícula 2015-2021» y la tarjeta «Matrícula del semestre 1 frente al año anterior»	Barras horizontales ordenadas de mayor a menor para comparar departamentos (categorías largas y un ranking); línea para la tendencia en el tiempo; tarjeta con referencia para la variación del último año	Por departamento, la matrícula se concentra en Bogotá, D.C. (cerca de 4,5 millones acumulados del semestre 1 entre 2015 y 2021), seguida de Antioquia (cerca de 1,8 millones) y Valle del Cauca (cerca de 1,0 millón). En el tiempo, la matrícula del semestre 1 pasó de 1.867.703 en 2015 a 1.995.185 en 2021 (+6,8 %), con una caída a 1.930.934 en 2020 y una recuperación de 3,33 % en 2021.
P1. ¿La matrícula por departamento es mayor en instituciones con acreditación de alta calidad que en las no acreditadas?	Página 2 «Acreditación»: «Matrícula por año según acreditación de la institución» y la tarjeta «% de matrícula en instituciones acreditadas frente al promedio»	Columnas agrupadas por año con una serie por categoría (SI/NO) para comparar dos grupos lado a lado en cada año; tarjeta para la proporción. El segmentador de departamentos permite repetir la comparación para cada departamento	Sí. Las instituciones acreditadas concentran el 58,25 % de la matrícula del semestre 1, y en los siete años la columna de acreditadas (entre 1,07 y 1,16 millones) supera a la de no acreditadas (entre 0,79 y 0,86 millones). En 2021 son cerca de 1,16 millones frente a 0,83 millones. La serie «(En blanco)» son las 78 filas cuya institución no está en el catálogo
P2. ¿Cómo se distribuye la matrícula por género en cada núcleo básico del conocimiento y año?	Página 3 «Género y áreas»: «Distribución por género en cada núcleo del conocimiento (Top 10)»	Barras apiladas al 100 % porque la pregunta compara la composición (proporción de mujeres y hombres) entre núcleos con tamaños muy distintos; los segmentadores de año y núcleo permiten ver cada año	La composición varía mucho entre núcleos: Psicología tiene cerca de 81 % de mujeres; Contaduría Pública, cerca de 65 %; Educación, cerca de 63 %; Administración y Medicina, cerca de 58 %; Ingeniería Civil y afines, cerca de 31 %; Ingeniería de Sistemas, Telemática y afines, cerca de 20 % (cerca de 80 % de hombres). Esta lectura depende del supuesto 1 = Masculino y 2 = Femenino

4.3 Capturas del tablero

Página 1. Matrícula (P0)



Página 2. Acreditación (P1)



Página 3. Género y áreas (P2)



4.4 Filtros

Página	Filtros o segmentadores	Dimensión	Visuales sobre los que actúan
1. Matrícula	Años (segmentador de mosaico)	dim_tiempo[anio]	Todos los visuales de la página
1. Matrícula	Departamentos (lista)	dim_geografia[nom_dpto]	Todos los visuales de la página
2. Acreditación	Años (segmentador de rango)	dim_tiempo[anio]	Todos los visuales de la página
2. Acreditación	Departamentos (lista)	dim_geografia[nom_dpto]	Todos los visuales de la página
3. Género y áreas	Años (segmentador de mosaico)	dim_tiempo[anio]	Todos los visuales de la página
3. Género y áreas	Áreas del conocimiento (lista)	dim_programa[nucleo_basico]	Todos los visuales de la página

Anexos

Anexo A. Consultas de conciliación

Estas consultas son las mismas de `dw/conciliacion/`.

`01_conteos_dw.sql` — conteos por tabla y hechos con llave «Desconocido»

```
-- Conciliación: conteos en el data warehouse (ejecutar después de la carga)
USE matricula;
SELECT 'dim_tiempo' AS tabla, COUNT(*) AS registros FROM dim_tiempo
UNION ALL SELECT 'dim_institucion', COUNT(*) FROM dim_institucion
UNION ALL SELECT 'dim_programa',    COUNT(*) FROM dim_programa
UNION ALL SELECT 'dim_geografia',   COUNT(*) FROM dim_geografia
UNION ALL SELECT 'dim_genero',      COUNT(*) FROM dim_genero
UNION ALL SELECT 'fact_matricula',  COUNT(*) FROM fact_matricula;

-- Filas de hechos que quedaron con la fila "Desconocido" (llave -1)
SELECT 'institucion' AS dimension, COUNT(*) AS filas_desconocido FROM fact_matricula WHERE
sk_institucion = -1
UNION ALL SELECT 'programa',   COUNT(*) FROM fact_matricula WHERE sk_programa  = -1
UNION ALL SELECT 'geografia',  COUNT(*) FROM fact_matricula WHERE sk_geografia = -1
UNION ALL SELECT 'genero',     COUNT(*) FROM fact_matricula WHERE sk_genero    = -1;
```

Resultado:

tabla	registros
dim_tiempo	14
dim_institucion	362
dim_programa	15.527
dim_geografia	1.123
dim_genero	3
fact_matricula	230.078

dimension	filas_desconocido
institucion	78
programa	0
geografia	0
genero	0

`02_totales_dw.sql` — total de la métrica y desglose por año y semestre

```
-- Conciliación: total de la métrica en el data warehouse
USE matricula;
SELECT SUM(total_matriculados) AS total_dw FROM fact_matricula;

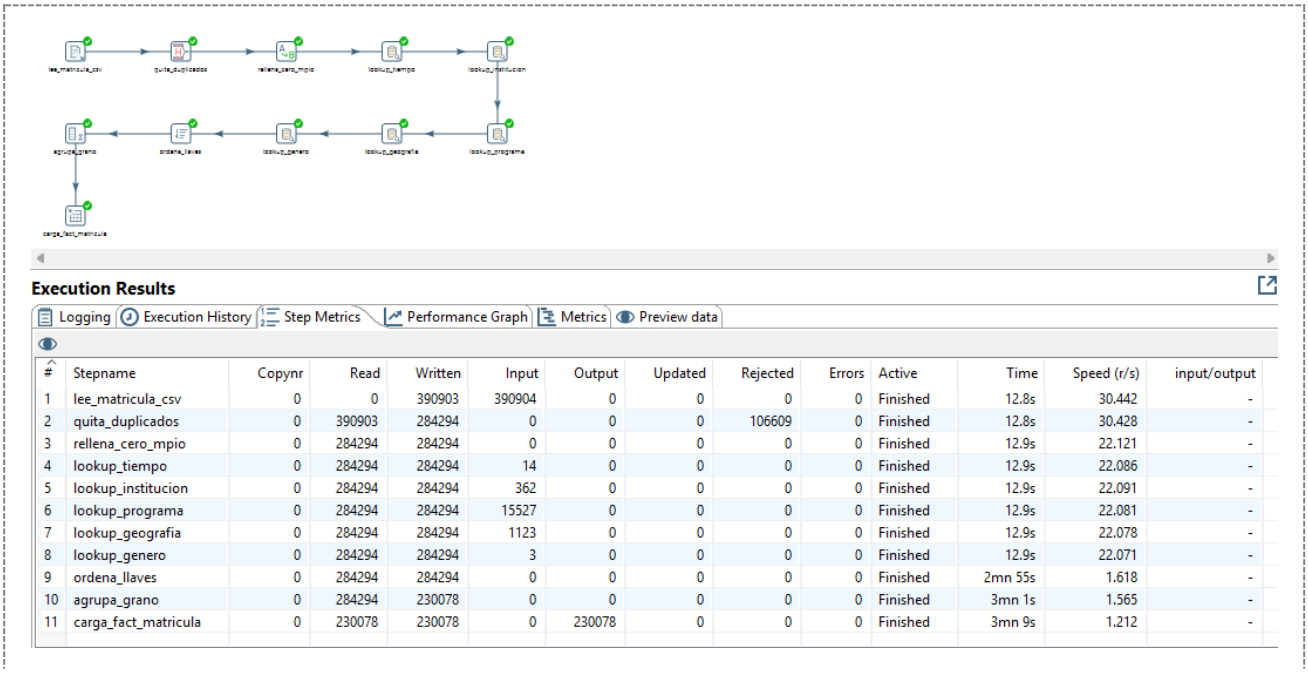
-- Desglose por año y semestre (para comparar con la fuente tras la limpieza)
SELECT t.anio, t.semestre, SUM(f.total_matriculados) AS total_matriculados
FROM fact_matricula f JOIN dim_tiempo t ON t.sk_tiempo = f.sk_tiempo
GROUP BY t.anio, t.semestre ORDER BY t.anio, t.semestre;
```

Resultado: `total_dw` = 16.774.645.

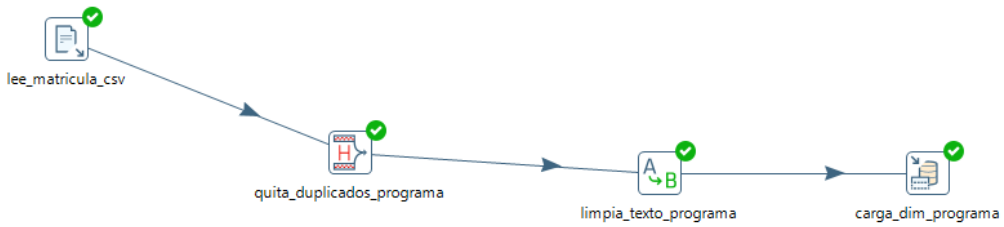
anio	semestre	total_matriculados
2015	1	1.867.703
2015	2	425.847
2016	1	1.963.744
2016	2	430.690
2017	1	1.978.671
2017	2	467.643
2018	1	1.976.710
2018	2	463.653
2019	1	1.965.140
2019	2	431.109
2020	1	1.930.934
2020	2	424.655
2021	1	1.995.185
2021	2	452.961

Anexo B. Capturas adicionales

Métricas de pasos de cada transformación



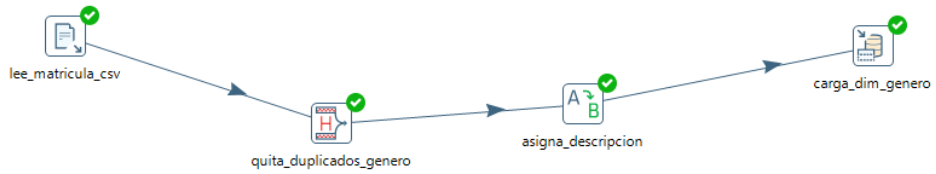
#	Stepname	Copynr	Read	Written	Input	Output	Updated	Rejected	Errors	Active	Time	Speed (r/s)	input/output
1	lee_matricula_csv	0	0	390903	390904	0	0	0	0	Finished	12.8s	30.442	-
2	quita_duplicados	0	390903	284294	0	0	0	106609	0	Finished	12.8s	30.428	-
3	rellena_cero_mpio	0	284294	284294	0	0	0	0	0	Finished	12.9s	22.121	-
4	lookup_tiempo	0	284294	284294	14	0	0	0	0	Finished	12.9s	22.086	-
5	lookup_institucion	0	284294	284294	362	0	0	0	0	Finished	12.9s	22.091	-
6	lookup_programa	0	284294	284294	15527	0	0	0	0	Finished	12.9s	22.081	-
7	lookup_geografia	0	284294	284294	1123	0	0	0	0	Finished	12.9s	22.078	-
8	lookup_genero	0	284294	284294	3	0	0	0	0	Finished	12.9s	22.071	-
9	ordena_llaves	0	284294	284294	0	0	0	0	0	Finished	2mn 55s	1.618	-
10	agrupa_grano	0	284294	230078	0	0	0	0	0	Finished	3mn 1s	1.565	-
11	carga_fact_matricula	0	230078	230078	0	230078	0	0	0	Finished	3mn 9s	1.212	-



xecution Results

Logging | Execution History | Step Metrics | Performance Graph | Metrics | Preview data

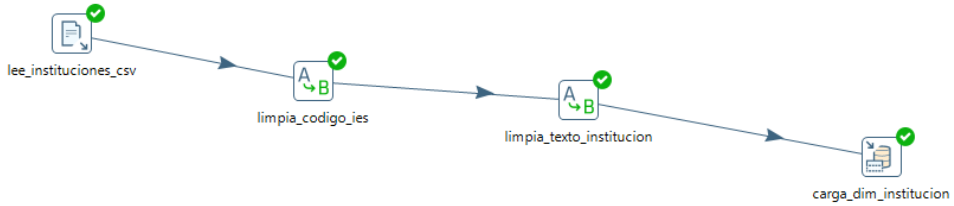
#	Stepname	Copynr	Read	Written	Input	Output	Updated	Rejected	Errors	Active	Time	Speed (r/s)
1	lee_matricula_csv	0	0	390903	390904	0	0	0	0	Finished	6.1s	64.399
2	quita_duplicados_programa	0	390903	15526	0	0	0	375377	0	Finished	6.1s	64.367
3	limpia_texto_programa	0	15526	15526	0	0	0	0	0	Finished	7.7s	2.016
4	carga_dim_programa	0	15526	15526	15526	0	0	0	0	Finished	13.8s	1.128



Execution Results

Logging | Execution History | Step Metrics | Performance Graph | Metrics | Preview data

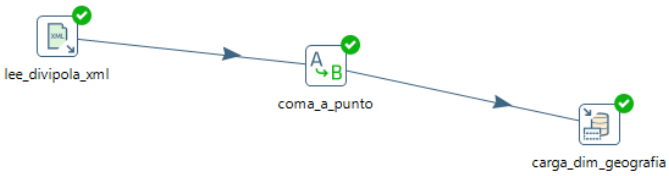
#	Stepname	Copynr	Read	Written	Input	Output	Updated	Rejected	Errors	Active	Time	Speed (r/s)	input/outp
1	lee_matricula_csv	0	0	390903	390904	0	0	0	0	Finished	4.3s	91.247	
2	quita_duplicados_genero	0	390903	2	0	0	0	390901	0	Finished	4.3s	90.571	
3	asigna_descripcion	0	2	2	0	0	0	0	0	Finished	4.3s	0	
4	carga_dim_genero	0	2	2	2	0	0	0	0	Finished	4.4s	0	



Execution Results

Logging | Execution History | Step Metrics | Performance Graph | Metrics | Preview data

#	Stepname	Copynr	Read	Written	Input	Output	Updated	Rejected	Errors	Active	Time	Speed (r/s)	input/output
1	lee_instituciones_csv	0	0	361	362	0	0	0	0	Finished	0.0s	22.625	-
2	limpia_codigo_ies	0	361	361	0	0	0	0	0	Finished	0.0s	10.028	-
3	limpia_texto_institucion	0	361	361	0	0	0	0	0	Finished	0.1s	6.942	-
4	carga_dim_institucion	0	361	361	361	0	0	0	0	Finished	0.7s	483	-



Execution Results

Logging | Execution History | Step Metrics | Performance Graph | Metrics | Preview data

#	Stepname	Copynr	Read	Written	Input	Output	Updated	Rejected	Errors	Active	Time	Speed (r/s)	input/output
1	lee_divipola_xml	0	0	1122	1122	0	0	0	0	Finished	0.2s	7.012	-
2	coma_a_punto	0	1122	1122	0	0	0	0	0	Finished	0.2s	6.375	-
3	carga_dim_geografia	0	1122	1122	1122	0	1122	0	0	Finished	1.4s	796	-